Linear Algebra for Applied Deep Learning

Notas de clase

Jairo de Jesús Blanco Pérez
Programa de Ingeniería de Sistemas, Universidad del Magdalena

Octubre de 2026

Resumen

Estas notas desarrollan los fundamentos de álgebra lineal que sostienen el cómputo de una red neuronal artificial: espacios vectoriales, matrices y producto matricial, combinación e independencia lineal, producto interno y normas vectoriales, normas matriciales y transformaciones lineales. El hilo conductor es la equivalencia, literal y no una analogía pedagógica, entre estas construcciones y los objetos de una red: el vector como registro de datos o como vector de activaciones, la matriz como conjunto de datos o como matriz de pesos de una capa, y la transformación afín $W\vec{x}+\vec{b}$ como la operación que cada capa aplica antes de su función de activación. Un mismo ejemplo, el modelo lineal que estima tiempos de entrega y su error cuadrático medio, acompaña las secciones y es el que se retoma en las notas de cálculo multivariable. Se asume como prerrequisito álgebra básica de bachillerato; no se asume cálculo ni experiencia previa en aprendizaje automático.

Índice

1 Introducción **2**

2 Espacios vectoriales y el dato como objeto algebraico **2**
2.1 Espacio vectorial 3
2.2 Subespacios vectoriales 3

3 Matrices, el dataset y el producto matricial **5**
3.1 La matriz como dataset 5
3.2 Operaciones básicas 6
3.3 El producto matricial 6

4 Combinación lineal e independencia lineal **8**
4.1 Combinación lineal 8
4.2 Independencia lineal 9

5 Producto interno y normas vectoriales **10**
5.1 Producto interno 10
5.2 Normas vectoriales 11

6 Normas matriciales **13**

7 Transformaciones lineales y la capa $W\vec{x} + \vec{b}$ **14**
7.1 Transformaciones lineales 14
7.2 La transformación afín $W\vec{x} + \vec{b}$ 15

8 Síntesis: del álgebra lineal al modelo **17**

1 Introducción

Una red neuronal artificial, y como caso más simple el perceptrón o la regresión lineal, es en su núcleo computacional álgebra lineal aplicada, capa tras capa: un conjunto de observaciones se organiza como una matriz, cada capa se representa mediante una matriz de pesos y un vector de sesgos, y su salida se obtiene con productos internos, productos matriciales y transformaciones afines. Esta correspondencia es literal. La suma ponderada que calcula una neurona es, por definición, un producto punto; una capa completa es la aplicación de una transformación lineal seguida de un corrimiento afín, y el *forward pass* de toda la red es la composición de estas transformaciones, una por capa. Comprender el álgebra lineal con precisión es, por tanto, un prerrequisito para derivar, y no solo usar, una red neuronal de una capa o de varias.

Las secciones 2 a 7 desarrollan los espacios vectoriales, las matrices y el producto matricial (en particular su lectura como combinación lineal de columnas), la combinación y la independencia lineal, el producto interno y las normas vectoriales, las normas matriciales y las transformaciones lineales. La Sección 8 reúne cada construcción con el componente de la red que representa.

Un mismo ejemplo acompaña el desarrollo: el modelo lineal $\hat{y} = \vec{w} \cdot \vec{x} + b$ que estima el tiempo de entrega de un pedido, con tres registros y el error cuadrático medio

$$\mathrm{MSE}(\vec{w}, b) = \frac{1}{2m} \sum_{i=1}^{m} \big(\hat{y}^{(i)} - y^{(i)}\big)^2,$$

que es el ejemplo de las notas de cálculo multivariable. Aquí se estudia con las herramientas de este documento; allí, cómo minimizar el MSE con derivadas.

Cada sección sigue el mismo patrón: se motiva el concepto en prosa, se formaliza mediante una definición numerada, se enuncian y justifican sus propiedades, se ilustra con un ejemplo numérico verificado y se propone al menos un ejercicio con solución completa.

Notación. Se usa m para el número de registros de un conjunto de datos y d para el número de atributos, de modo que una matriz de datos es $X \in \mathbb{R}^{m \times d}$. Una capa con p neuronas tiene matriz de pesos $W \in \mathbb{R}^{p \times d}$. Las matrices genéricas se escriben $A \in \mathbb{R}^{p \times q}$.

2 Espacios vectoriales y el dato como objeto algebraico

En ciencia de datos, la primera decisión de modelado, a menudo implícita, es representar cada observación como un punto de un espacio con estructura algebraica, de modo que operaciones como el promedio, la diferencia entre observaciones o el centrado de datos tengan un significado preciso y no sean meras manipulaciones de arreglos numéricos. El espacio vectorial es la estructura mínima que da ese significado: garantiza que sumar dos observaciones y escalar una observación produzcan de nuevo un objeto del mismo tipo, y que esas operaciones se comporten de forma predecible.

2.1 Espacio vectorial

Definición 2.1 (Espacio vectorial)**.** Un *espacio vectorial sobre* $\mathbb{R}$ es un conjunto V dotado de dos operaciones, la suma $+\colon V \times V \to V$ y la multiplicación por escalar $\cdot\colon \mathbb{R} \times V \to V$, tales que para todo $u, v, w \in V$ y todo $\alpha, \lambda \in \mathbb{R}$ se cumple:

1. Cerradura: $u + v \in V$ y $\lambda v \in V$.
2. Conmutatividad: $u + v = v + u$.
3. Asociatividad: $(u + v) + w = u + (v + w)$ y $\alpha(\lambda u) = (\alpha\lambda)u$.
4. Neutro aditivo: existe $0 \in V$ tal que $v + 0 = v$.
5. Inverso aditivo: para cada $v \in V$ existe $-v \in V$ tal que $v + (-v) = 0$.
6. Distributividad: $\lambda(u + v) = \lambda u + \lambda v$ y $(\alpha + \lambda)v = \alpha v + \lambda v$.
7. Neutro multiplicativo: $1 \cdot v = v$.

Esta axiomatización es estándar en la literatura de álgebra lineal [2]. El espacio con el que se trabaja en la práctica, casi exclusivamente en este documento, es $\mathbb{R}^d$, el espacio estándar de d-tuplas de números reales.

Ejemplo 2.2 (El vector como registro de datos)**.** Un vector $\vec{x} \in \mathbb{R}^d$ representa habitualmente un registro con d atributos y se escribe como matriz columna $\vec{x} = (x_1, \ldots, x_d)^T \in \mathbb{R}^d$. En el modelo de tiempos de entrega, cada pedido tiene dos atributos: la distancia al destino en kilómetros (x_1) y el número de paradas previas del repartidor (x_2). El primer pedido, con 1 km y 2 paradas previas, es $\vec{x}^{(1)} = (1, 2)^T \in \mathbb{R}^2$. El vector de pesos del modelo, $\vec{w} = (w_1, w_2)^T$, también vive en $\mathbb{R}^2$. $\mathbb{R}^d$ con la suma y el escalado usuales de tuplas es un espacio vectorial; es, de hecho, el ejemplo canónico de espacio vectorial de dimensión finita.

Observación 2.3. Cuando $V = \mathbb{R}^d$ en su totalidad, verificar la cerradura de una operación es trivial: cualquier combinación de tuplas reales de longitud d es, por definición, una tupla real de longitud d. Por ejemplo, el centrado de datos $\tilde{\vec{x}}^{(i)} = \vec{x}^{(i)} - \bar{\vec{x}}$, con $\bar{\vec{x}} = \frac{1}{m}\sum_{i=1}^{m} \vec{x}^{(i)}$, operación usada en el preprocesamiento previo a técnicas como PCA, no saca a $\tilde{\vec{x}}^{(i)}$ de $\mathbb{R}^d$. En los tres pedidos del modelo de entregas (Tabla 1), $\bar{\vec{x}} = (2, 2)^T$ y $\tilde{\vec{x}}^{(1)} = (-1, 0)^T$, $\tilde{\vec{x}}^{(2)} = (0, -1)^T$, $\tilde{\vec{x}}^{(3)} = (1, 1)^T$. La verificación de cerradura solo es informativa cuando se aplica a un *subconjunto propio* de un espacio vectorial, es decir, a un subespacio candidato: ahí la cerradura no está garantizada de antemano y debe demostrarse.

2.2 Subespacios vectoriales

Si $\mathbb{R}^d$ completo no ofrece un caso de prueba interesante, el objeto que sí lo ofrece es el subespacio: un subconjunto que hereda la estructura de espacio vectorial de su espacio ambiente, pero cuya pertenencia no es automática.

Definición 2.4 (Subespacio vectorial)**.** Un subconjunto no vacío $W \subseteq V$ de un espacio vectorial V es un *subespacio* de V si W es cerrado bajo las operaciones de V, es decir, si para todo $u, v \in W$ y $\lambda \in \mathbb{R}$ se tiene $u + v \in W$ y $\lambda v \in W$. Bajo estas condiciones, W satisface por herencia el resto de los axiomas de espacio vectorial [2].

Proposición 2.5. *El conjunto* $W = \{(x_1, x_2, x_3) \in \mathbb{R}^3 : x_1 + x_2 + x_3 = 0\}$ *es un subespacio de* $\mathbb{R}^3$.

Demostración. W no es vacío, pues $(0,0,0) \in W$. Sean $u = (u_1, u_2, u_3)$ y $v = (v_1, v_2, v_3)$ en W, de modo que $u_1 + u_2 + u_3 = 0$ y $v_1 + v_2 + v_3 = 0$.

Cerradura bajo la suma. Las componentes de $u + v$ suman

$$\begin{aligned}(u_1 + v_1) + (u_2 + v_2) + (u_3 + v_3) &= (u_1 + u_2 + u_3) + (v_1 + v_2 + v_3) \\ &= 0 + 0 \\ &= 0,\end{aligned}$$

luego $u + v \in W$.

Cerradura bajo el escalado. Para $\lambda \in \mathbb{R}$, las componentes de λu suman

$$\begin{aligned}\lambda u_1 + \lambda u_2 + \lambda u_3 &= \lambda(u_1 + u_2 + u_3) \\ &= \lambda \cdot 0 \\ &= 0,\end{aligned}$$

luego $\lambda u \in W$. Se concluye que W es cerrado bajo suma y escalado y, por lo tanto, es un subespacio de $\mathbb{R}^3$. □

Ejemplo 2.6. Sean $u = (1, -1, 0)$ y $v = (2, 0, -2)$, ambos en W, pues sus componentes suman 0 en los dos casos. Se verifica numéricamente que

$$u + v = (3, -1, -2), \qquad 3 - 1 - 2 = 0,$$

y que

$$3u = (3, -3, 0), \qquad 3 - 3 + 0 = 0;$$

ambos resultados permanecen en W, como garantiza la Proposición 2.5.

Ejercicio 2.7. Determine si $H = \{(x_1, x_2, x_3) \in \mathbb{R}^3 : x_1 = 2x_2\}$ es un subespacio de $\mathbb{R}^3$.

Solución. H no es vacío, pues $(0,0,0) \in H$. Como caso particular, con $u = (2, 1, 5)$ y $v = (-4, -2, 0)$ (ambos en H, pues $2 = 2 \cdot 1$ y $-4 = 2 \cdot (-2)$):

$$u + v = (-2, -1, 5), \quad -2 = 2 \cdot (-1); \qquad 3u = (6, 3, 15), \quad 6 = 2 \cdot 3,$$

de modo que $u + v \in H$ y $3u \in H$.

En general, para $u = (2u_2, u_2, u_3)$ y $v = (2v_2, v_2, v_3)$ arbitrarios en H, la primera componente de $u + v$ es

$$2u_2 + 2v_2 = 2(u_2 + v_2),$$

exactamente el doble de la segunda componente $u_2 + v_2$; el mismo argumento aplica al escalado. Por lo tanto H es cerrado bajo ambas operaciones y es un subespacio de $\mathbb{R}^3$. △

Ejercicio 2.8. Determine si $S = \{(x, y) \in \mathbb{R}^2 : xy = 0\}$ es un subespacio de $\mathbb{R}^2$.

Síntesis de la sección

Un espacio vectorial formaliza cuándo sumar y escalar objetos produce resultados del mismo tipo y con comportamiento predecible; $\mathbb{R}^d$ es el espacio vectorial estándar, y el vector $\vec{x} \in \mathbb{R}^d$ es, en una red neuronal artificial, tanto un registro de entrada como el vector de activaciones que una capa entrega a la siguiente. Verificar que un subconjunto propio de $\mathbb{R}^d$ es un subespacio, no que $\mathbb{R}^d$ mismo lo sea, es la comprobación con contenido real, porque exige demostrar cerradura sin darla por garantizada. Con esta base, el lector debe poder decidir, dado un subconjunto definido por una condición algebraica, si es o no un subespacio, y justificarlo con una demostración completa o un contraejemplo.

Soluciones de los ejercicios

Ejercicio 2.8. *S no* es un subespacio de $\mathbb{R}^2$. Contraejemplo: sean $u = (1, 0)$ y $v = (0, 1)$, ambos en S, pues

$$1 \cdot 0 = 0 \qquad \text{y} \qquad 0 \cdot 1 = 0.$$

Sin embargo,

$$u + v = (1, 1), \qquad 1 \cdot 1 = 1 \neq 0,$$

luego $u + v \notin S$. S no es cerrado bajo la suma y, por lo tanto, no es un subespacio de $\mathbb{R}^2$ (geométricamente, S es la unión de los dos ejes coordenados, que no es un subespacio aunque cada eje por separado sí lo es).

3 Matrices, el dataset y el producto matricial

Si el vector representa un único registro, la matriz representa una colección completa de registros, y las operaciones que se realizan sobre un dataset (predecir todas las observaciones a la vez, proyectar los datos a otro espacio de representación, aplicar una capa de una red a un lote de entradas) se expresan de forma natural como productos matriciales. Fijar con precisión qué es y qué no es un producto matricial, y qué información codifica, es indispensable antes de interpretar una capa de red como una transformación lineal (Sección 7).

3.1 La matriz como dataset

Definición 3.1 (Matriz de datos)**.** Una matriz $X \in \mathbb{R}^{m \times d}$ es un arreglo rectangular de m filas y d columnas. En ciencia de datos, X se interpreta como un *dataset* donde $x_j^{(i)}$ es el valor del atributo (*feature*) j-ésimo en el registro i-ésimo; así, X contiene m registros descritos por d atributos cada uno. Cada fila de X es un vector $\vec{x}^{(i)} \in \mathbb{R}^d$ (un registro completo, escrito como fila $\vec{x}^{(i)T}$) y cada columna es un vector $\vec{x}_j \in \mathbb{R}^m$ (los valores de un atributo a través de todos los registros) [1].

Ejemplo 3.2 (Conjunto de datos de entregas)**.** Para la empresa de domicilios, el conjunto de datos tiene $m = 3$ registros y $d = 2$ atributos: distancia al destino en kilómetros (x_1) y número de paradas previas del repartidor (x_2), con el tiempo real de entrega y en minutos (Tabla 1).

Tabla 1: Registros del conjunto de datos de entregas.

Entrega i	$x_1^{(i)}$ (km)	$x_2^{(i)}$ (paradas previas)	$y^{(i)}$ (min reales)
1	1	2	6
2	2	1	5
3	3	3	12

La matriz de datos y el vector de etiquetas son

$$X = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 3 \end{pmatrix} \in \mathbb{R}^{3 \times 2}, \qquad \vec{y} = \begin{pmatrix} 6 \\ 5 \\ 12 \end{pmatrix} \in \mathbb{R}^3.$$

La primera fila, $\vec{x}^{(1)T} = (1, 2)$, describe por completo la entrega 1; la primera columna, $\vec{x}_1 = (1, 2, 3)^T \in \mathbb{R}^3$, reúne las distancias de las tres entregas [1].

3.2 Operaciones básicas

Para $\vec{x}, \vec{y} \in \mathbb{R}^d$ y $\lambda \in \mathbb{R}$, la suma y el escalado se definen componente a componente, $(\vec{x}+\vec{y})_i = x_i + y_i$ y $(\lambda\vec{x})_i = \lambda x_i$, y para $X \in \mathbb{R}^{m\times d}$ la transpuesta $X^T \in \mathbb{R}^{d\times m}$ se define por $(X^T)_{ji} = X_{ij}$: la fila i de X pasa a ser la columna i de X^T. La transposición es, en la práctica, una de las operaciones más usadas en ciencia de datos, típicamente para alinear las dimensiones de un producto matricial [1].

3.3 El producto matricial

Definición 3.3 (Producto matriz–vector)**.** Dadas $A \in \mathbb{R}^{p\times q}$ y $\vec{x} \in \mathbb{R}^q$, el producto $A\vec{x} \in \mathbb{R}^p$ se define componente a componente como

$$(A\vec{x})_i = \sum_{j=1}^{q} A_{ij}x_j, \qquad i = 1, \ldots, p.$$

Teorema 3.4 ($A\vec{x}$ como combinación lineal de columnas)**.** *Si $\vec{a}_1, \ldots, \vec{a}_q \in \mathbb{R}^p$ son las columnas de $A \in \mathbb{R}^{p\times q}$ y $\vec{x} = (x_1, \ldots, x_q)^T$, entonces*

$$A\vec{x} = x_1\vec{a}_1 + x_2\vec{a}_2 + \cdots + x_q\vec{a}_q.$$

Demostración. Por la Definición 3.3, la componente i de $A\vec{x}$ es $\sum_{j=1}^{q} A_{ij}x_j$. La componente i del lado derecho es $\sum_{j=1}^{q} x_j(\vec{a}_j)_i = \sum_{j=1}^{q} x_j A_{ij}$, que es la misma suma reordenada. Como ambos lados coinciden componente a componente, son iguales. □

Este teorema es el puente hacia la combinación lineal (Sección 4): multiplicar una matriz por un vector no es una operación ajena a la combinación lineal, es una combinación lineal, con las columnas de la matriz como vectores y las entradas de $\vec{x}$ como coeficientes.

Ejemplo 3.5. Sea $A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$ y $\vec{x} = (1, 0, -1)^T$. Por la Definición 3.3,

$$A\vec{x} = \big(1(1) + 2(0) + 3(-1),\ 4(1) + 5(0) + 6(-1)\big)^T = (-2, -2)^T.$$

Por el Teorema 3.4, el mismo resultado se obtiene como combinación de columnas:

$$1 \cdot (1, 4)^T + 0 \cdot (2, 5)^T + (-1) \cdot (3, 6)^T = (1, 4)^T - (3, 6)^T = (-2, -2)^T.$$

Ejemplo 3.6 (Predicción del modelo de entregas)**.** Con los datos del Ejemplo 3.2, el modelo $\hat{y}^{(i)} = \vec{w} \cdot \vec{x}^{(i)} + b$ evaluado en $\vec{w} = (2, 1)^T$ y $b = 1$ sobre los tres registros a la vez es

$$X\vec{w} = \begin{pmatrix} 1(2) + 2(1) \\ 2(2) + 1(1) \\ 3(2) + 3(1) \end{pmatrix} = \begin{pmatrix} 4 \\ 5 \\ 9 \end{pmatrix}, \qquad \hat{\vec{y}} = X\vec{w} + b\,\mathbf{1} = \begin{pmatrix} 5 \\ 6 \\ 10 \end{pmatrix},$$

donde $\mathbf{1} = (1, 1, 1)^T$ es el vector de unos. Por el Teorema 3.4, $X\vec{w} = 2\,\vec{x}_1 + 1\,\vec{x}_2 = 2(1, 2, 3)^T + (2, 1, 3)^T = (4, 5, 9)^T$, el mismo resultado. Estas son las predicciones $5, 6, 10$ con las que se calcula $\mathrm{MSE}(2, 1, 1) = 1\ \mathrm{min}^2$ en las notas de cálculo multivariable.

Definición 3.7 (Producto matriz–matriz)**.** Dadas $A \in \mathbb{R}^{p\times q}$ y $B \in \mathbb{R}^{q\times r}$, el producto $AB \in \mathbb{R}^{p\times r}$ se define por $(AB)_{ik} = \sum_{j=1}^{q} A_{ij}B_{jk}$; equivalentemente, la columna k de AB es A multiplicada por la columna k de B (aplicación repetida de la Definición 3.3) [2]. El producto solo está definido cuando el número de columnas de A coincide con el número de filas de B.

Proposición 3.8 (No conmutatividad)**.** *En general, $AB \neq BA$, incluso cuando ambos productos están definidos y tienen las mismas dimensiones.*

Demostración. Basta un contraejemplo. Sean $M_1 = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ y $M_2 = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}$. Entonces $M_1 M_2 = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$ mientras que $M_2 M_1 = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$, y $M_1 M_2 \neq M_2 M_1$. □

Observación 3.9. La no conmutatividad no es una patología ocasional: en general ni siquiera está garantizado que BA esté definido cuando AB lo está. Si $A \in \mathbb{R}^{2\times 3}$ y $B \in \mathbb{R}^{3\times 2}$, el producto $AB \in \mathbb{R}^{2\times 2}$ existe, pero $BA \in \mathbb{R}^{3\times 3}$ también existe y tiene una forma completamente distinta: no son siquiera comparables como matrices, y mucho menos iguales. Esto importa en una red: el orden de las capas importa.

Ejercicio 3.10. Con $A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$ y $B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$, calcule AB y BA, y verifique que tienen dimensiones distintas.

Solución. Para $AB \in \mathbb{R}^{2\times 2}$, se calcula cada entrada con la Definición 3.3, aplicada una vez por columna de B:

$$(AB)_{11} = 1(1) + 2(0) + 3(1) = 4, \qquad (AB)_{12} = 1(0) + 2(1) + 3(1) = 5,$$
$$(AB)_{21} = 4(1) + 5(0) + 6(1) = 10, \qquad (AB)_{22} = 4(0) + 5(1) + 6(1) = 11.$$

Así,

$$AB = \begin{pmatrix} 4 & 5 \\ 10 & 11 \end{pmatrix}.$$

Para $BA \in \mathbb{R}^{3\times 3}$, cada fila de BA es la fila correspondiente de B multiplicada por A:

$$\begin{aligned} &\text{fila 1 de } B = (1,0): && (1,0)A = (1,2,3), \\ &\text{fila 2 de } B = (0,1): && (0,1)A = (4,5,6), \\ &\text{fila 3 de } B = (1,1): && (1,1)A = (1+4,\ 2+5,\ 3+6) = (5,7,9). \end{aligned}$$

Así,

$$BA = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 5 & 7 & 9 \end{pmatrix}.$$

En efecto, AB es 2×2 y BA es 3×3: no son comparables. △

Ejercicio 3.11. Escriba $A\vec{x}$ como combinación lineal de las columnas de A, para $A = \begin{pmatrix} 2 & 0 & -1 \\ 1 & 3 & 1 \end{pmatrix}$ y $\vec{x} = (1, 2, -1)^T$, y calcule el resultado.

Síntesis de la sección

Una matriz $X \in \mathbb{R}^{m\times d}$ formaliza un dataset de m registros con d atributos o, equivalentemente, la matriz de pesos W de una capa de una red; el producto matriz–vector $A\vec{x}$ no es una operación independiente de la combinación lineal, sino exactamente una combinación lineal de las columnas

de A ponderada por las entradas de $\vec{x}$ (Teorema 3.4); y el producto matriz–matriz extiende esa misma idea columna a columna. Es, de hecho, la operación que permite calcular el forward pass de una capa sobre un lote (*batch*) completo de entradas a la vez, en lugar de una por una, sin ser en general conmutativo ni, muchas veces, siquiera definido en ambos órdenes. Con esta base, el lector debe poder calcular productos matriciales a mano y reconocer, en cualquier producto $A\vec{x}$, la combinación lineal de columnas que representa.

Soluciones de los ejercicios

Ejercicio 3.11. Las columnas de A son $\vec{a}_1 = (2,1)^T$, $\vec{a}_2 = (0,3)^T$, $\vec{a}_3 = (-1,1)^T$, y $\vec{x} = (1,2,-1)^T$. Por el Teorema 3.4,

$$\begin{aligned} A\vec{x} &= 1 \cdot (2,1)^T + 2 \cdot (0,3)^T + (-1) \cdot (-1,1)^T \\ &= (2,1)^T + (0,6)^T + (1,-1)^T \\ &= (3,6)^T. \end{aligned}$$

Verificación directa con la Definición 3.3:

$$\big(2(1)+0(2)+(-1)(-1),\ 1(1)+3(2)+1(-1)\big) = (2+0+1,\ 1+6-1) = (3,6),$$

que coincide.

4 Combinación lineal e independencia lineal

El Teorema 3.4 mostró que multiplicar una matriz por un vector es, en esencia, formar una combinación de columnas. Esa misma operación, ponderar un conjunto de vectores por coeficientes y sumarlos, aparece en ciencia de datos cada vez que se combinan las salidas de varios modelos en un ensamble, y su contraparte, la independencia lineal, aparece cada vez que se necesita decidir si un atributo de un dataset aporta información nueva o es redundante frente a los demás.

4.1 Combinación lineal

Definición 4.1 (Combinación lineal)**.** Dado un conjunto de vectores $\{\vec{v}_1, \vec{v}_2, \ldots, \vec{v}_k\} \subset \mathbb{R}^d$, una *combinación lineal* de ellos es cualquier vector de la forma

$$\vec{w} = \sum_{i=1}^{k} c_i \vec{v}_i = c_1\vec{v}_1 + c_2\vec{v}_2 + \cdots + c_k\vec{v}_k, \qquad c_i \in \mathbb{R}.$$

Ejemplo 4.2 (Ensamble de modelos)**.** En un problema de predicción de demanda diaria, un ingeniero dispone de tres modelos con predicciones $\vec{y}^1, \vec{y}^2, \vec{y}^3 \in \mathbb{R}^{365}$ (una regresión lineal, un árbol de decisión y un perceptrón), y construye la predicción final como la combinación lineal $\hat{\vec{y}} = c_1\vec{y}^1 + c_2\vec{y}^2 + c_3\vec{y}^3$ con $c_1 + c_2 + c_3 = 1$ (una ponderación por nivel de confianza en cada modelo). Con $c_1 = 0.5$, $c_2 = 0.3$, $c_3 = 0.2$, y las predicciones del día 30 $y^1_{30} = 120$, $y^2_{30} = 150$, $y^3_{30} = 90$, la predicción final es

$$\hat{y}_{30} = 0.5(120) + 0.3(150) + 0.2(90) = 60 + 45 + 18 = 123 \text{ unidades.}$$

Esta técnica, una combinación lineal de las salidas de varios modelos, se conoce como *ensamble de modelos*.

Ejemplo 4.3 (El modelo lineal como combinación lineal)**.** Por el Ejemplo 3.6, el vector de predicciones del modelo de entregas es

$$\hat{\vec{y}} = w_1\,\vec{x}_1 + w_2\,\vec{x}_2 + b\,\mathbf{1},$$

una combinación lineal de las dos columnas de atributos y de la columna de unos, con los parámetros $\vec{\theta} = (w_1, w_2, b)$ como coeficientes. Entrenar el modelo consiste en elegir esos coeficientes para que $\hat{\vec{y}}$ quede lo más cerca posible de $\vec{y}$.

4.2 Independencia lineal

Definición 4.4 (Independencia lineal)**.** Un conjunto de vectores $\{\vec{v}_1, \ldots, \vec{v}_k\} \subset \mathbb{R}^d$ es *linealmente independiente* si la única combinación lineal de ellos que produce el vector cero es la que tiene todos los coeficientes iguales a cero:

$$\{\vec{v}_1, \ldots, \vec{v}_k\} \text{ es L.I.} \iff \sum_{i=1}^{k} c_i\vec{v}_i = \vec{0} \implies c_1 = c_2 = \cdots = c_k = 0.$$

Si existe una combinación no trivial (con algún $c_i \neq 0$) que produzca $\vec{0}$, el conjunto es *linealmente dependiente*.

Observación 4.5. Si $\{\vec{v}_1, \ldots, \vec{v}_k\}$ es linealmente dependiente, entonces algún $\vec{v}_j$ puede escribirse como combinación lineal de los demás: basta despejarlo de la relación $\sum_i c_i\vec{v}_i = \vec{0}$ usando un coeficiente $c_j \neq 0$. En ciencia de datos, esto significa que la columna j de un dataset no aporta información que no estuviera ya codificada en las demás columnas: ocupa espacio en memoria sin aumentar la capacidad predictiva, y su detección es la base formal de técnicas de selección de atributos (*feature selection*) [1].

Ejemplo 4.6 (Dependencia lineal por redundancia de atributos)**.** Una planta industrial registra tres atributos por muestra de tiempo: temperatura ($\vec{x}_1$), presión ($\vec{x}_2$) y un índice de eficiencia ($\vec{x}_3$) que el equipo de ingeniería calculó como $\vec{x}_3 = 2\vec{x}_1 - 0.5\vec{x}_2$ [1]. Reescribiendo, $2\vec{x}_1 - 0.5\vec{x}_2 - \vec{x}_3 = \vec{0}$, una combinación lineal no trivial (coeficientes $c_1 = 2$, $c_2 = -0.5$, $c_3 = -1$) que produce el vector cero. Por lo tanto $\{\vec{x}_1, \vec{x}_2, \vec{x}_3\}$ es linealmente dependiente, y el atributo $\vec{x}_3$ puede eliminarse del dataset sin pérdida de información, pues se reconstruye exactamente a partir de $\vec{x}_1$ y $\vec{x}_2$.

Ejemplo 4.7 (Independencia en el modelo de entregas)**.** Las columnas de $[\,\vec{x}_1\ \vec{x}_2\ \mathbf{1}\,]$ del Ejemplo 3.2 son $(1,2,3)^T$, $(2,1,3)^T$ y $(1,1,1)^T$. La relación $c_1\vec{x}_1 + c_2\vec{x}_2 + c_3\mathbf{1} = \vec{0}$ da el sistema

$$c_1 + 2c_2 + c_3 = 0, \qquad 2c_1 + c_2 + c_3 = 0, \qquad 3c_1 + 3c_2 + c_3 = 0.$$

Restando la primera ecuación de la segunda, $c_1 - c_2 = 0$; restando la segunda de la tercera, $c_1 + 2c_2 = 0$. De ambas, $c_1 = c_2 = 0$ y entonces $c_3 = 0$. Las tres columnas son linealmente independientes (el determinante de la matriz es $3 \neq 0$), de modo que ningún parámetro de $\vec{\theta} = (w_1, w_2, b)$ es redundante respecto de los otros.

Ejercicio 4.8. Determine si $\{\vec{v}_1, \vec{v}_2, \vec{v}_3\}$ con $\vec{v}_1 = (1,0,1)$, $\vec{v}_2 = (0,1,1)$, $\vec{v}_3 = (1,1,3)$ es linealmente independiente.

Solución. Se plantea $c_1\vec{v}_1 + c_2\vec{v}_2 + c_3\vec{v}_3 = \vec{0}$, lo que da el sistema

$$c_1 + c_3 = 0, \qquad c_2 + c_3 = 0, \qquad c_1 + c_2 + 3c_3 = 0.$$

De las dos primeras ecuaciones, $c_1 = -c_3$ y $c_2 = -c_3$. Sustituyendo en la tercera:

$$-c_3 - c_3 + 3c_3 = c_3 = 0,$$

luego $c_3 = 0$ y, en consecuencia, $c_1 = c_2 = 0$. La única solución es la trivial, por lo que $\{\vec{v}_1, \vec{v}_2, \vec{v}_3\}$ es linealmente independiente. (Verificación: el determinante de la matriz $[\vec{v}_1\ \vec{v}_2\ \vec{v}_3]$ es 1, distinto de cero, lo que confirma independencia.) △

Ejercicio 4.9. Un dataset de sensores registra $\vec{x}_1 = (1, 2, 3)$, $\vec{x}_2 = (2, 4, 6)$ y $\vec{x}_3 = (1, 0, -1)$. ¿Es $\{\vec{x}_1, \vec{x}_2, \vec{x}_3\}$ linealmente independiente? Si no lo es, indique qué atributo podría eliminarse.

Síntesis de la sección

Una combinación lineal pondera y suma vectores (el mecanismo exacto de un ensamble de modelos y de las predicciones de un modelo lineal); un conjunto es linealmente independiente cuando ninguno de sus vectores se deja escribir como combinación lineal de los demás, y es linealmente dependiente en caso contrario, lo que en un dataset señala un atributo redundante que puede eliminarse sin pérdida de información, y en una matriz de pesos señala una dirección que no aporta capacidad expresiva adicional a la capa. Con esta base, el lector debe poder plantear y resolver el sistema de ecuaciones que decide la independencia lineal de un conjunto concreto de vectores.

Soluciones de los ejercicios

Ejercicio 4.9. Se observa que $\vec{x}_2 = 2\vec{x}_1$, es decir, $2\vec{x}_1 - \vec{x}_2 + 0 \cdot \vec{x}_3 = \vec{0}$ es una combinación no trivial (coeficientes $c_1 = 2$, $c_2 = -1$, $c_3 = 0$) que produce el vector cero. Por lo tanto el conjunto es linealmente dependiente, y el atributo $\vec{x}_2$ (o, simétricamente, $\vec{x}_1$) podría eliminarse, pues es un múltiplo escalar exacto del otro y no aporta información adicional; $\vec{x}_3$ sí es necesario, pues no es múltiplo de $\vec{x}_1$.

5 Producto interno y normas vectoriales

Hasta aquí, las operaciones de un espacio vectorial permiten sumar y escalar registros, pero no permiten aún responder dos preguntas centrales en aprendizaje automático: qué tan *parecidos* son dos registros, y qué tan *grande* es un vector de pesos o un vector de error. El producto interno responde la primera; la norma, construida a partir del producto interno, responde la segunda. Ambas nociones son, además, el cómputo exacto que realiza una neurona artificial y el que define el error cuadrático medio.

5.1 Producto interno

Definición 5.1 (Producto interno canónico en $\mathbb{R}^d$)**.** Dados $\vec{u}, \vec{v} \in \mathbb{R}^d$, el *producto interno* (o producto punto) se define algebraicamente como

$$\vec{u} \cdot \vec{v} = \sum_{i=1}^{d} u_i v_i.$$

Proposición 5.2 (Propiedades del producto interno)**.** *Para $\vec{u}, \vec{v}, \vec{w} \in \mathbb{R}^d$ y $\lambda \in \mathbb{R}$:*

a) Simetría: $\vec{u} \cdot \vec{v} = \vec{v} \cdot \vec{u}$.

b) Bilinealidad: $\vec{u}\cdot(\vec{v}+\vec{w}) = \vec{u}\cdot\vec{v}+\vec{u}\cdot\vec{w}$ *y* $(\lambda\vec{u})\cdot\vec{v} = \lambda(\vec{u}\cdot\vec{v})$.

c) Positividad: $\vec{u}\cdot\vec{u}\geq 0$*, con igualdad si y solo si* $\vec{u}=\vec{0}$.

Demostración. Las tres propiedades se verifican directamente sobre la suma finita de la Definición 5.1: (a) y (b) son consecuencia de la conmutatividad y distributividad de la suma y el producto en $\mathbb{R}$; (c) es consecuencia de que $\vec{u}\cdot\vec{u} = \sum_i u_i^2$ es una suma de cuadrados, no negativa, y nula únicamente cuando cada $u_i = 0$ [2]. □

Teorema 5.3 (Interpretación geométrica)**.** *Para* $\vec{u},\vec{v}\in\mathbb{R}^d$ *no nulos,* $\vec{u}\cdot\vec{v} = \|\vec{u}\|\|\vec{v}\|\cos\alpha$*, donde* α *es el ángulo entre* $\vec{u}$ *y* $\vec{v}$ *(y* $\|\cdot\|$ *es la norma euclidiana, definida más abajo). En particular,* $\vec{u}\cdot\vec{v}=0$ *si y solo si* $\vec{u}$ *y* $\vec{v}$ *son ortogonales.*

Demostración. Es consecuencia de la ley de los cosenos aplicada al triángulo formado por $\vec{u}$, $\vec{v}$ y $\vec{u}-\vec{v}$; véase [2, cap. 1] para la demostración completa. □

Ejemplo 5.4. Con $\vec{u} = (1,2,3)$ y $\vec{v} = (4,-1,2)$,

$$\vec{u}\cdot\vec{v} = 1(4)+2(-1)+3(2) = 4-2+6 = 8.$$

Con las normas calculadas más abajo, $\|\vec{u}\| = \sqrt{14}\approx 3.742$ y $\|\vec{v}\| = \sqrt{21}\approx 4.583$, el Teorema 5.3 da

$$\cos\alpha = \frac{8}{\sqrt{14}\sqrt{21}} \approx 0.4666, \qquad \text{es decir,} \qquad \alpha \approx 62.19^\circ.$$

5.2 Normas vectoriales

Definición 5.5 (Norma p)**.** Para $\vec{x}\in\mathbb{R}^d$ y $p\geq 1$, la *norma* p de $\vec{x}$ se define como

$$\|\vec{x}\|_p = \Big(\sum_{i=1}^{d}|x_i|^p\Big)^{1/p},$$

con los casos particulares $\|\vec{x}\|_1 = \sum_i|x_i|$ y $\|\vec{x}\|_\infty = \max_i|x_i|$ (este último como límite de $\|\vec{x}\|_p$ cuando $p\to\infty$) [2].

Proposición 5.6 (La norma euclidiana como norma inducida)**.** $\|\vec{x}\|_2 = \sqrt{\vec{x}\cdot\vec{x}}$*: la norma* 2 *(norma euclidiana) es la norma inducida por el producto interno de la Definición 5.1.*

Demostración. Por la Definición 5.1, $\vec{x}\cdot\vec{x} = \sum_i x_i^2$, y por la definición de norma p con $p=2$, $\|\vec{x}\|_2 = \big(\sum_i x_i^2\big)^{1/2} = \sqrt{\vec{x}\cdot\vec{x}}$. □

Observación 5.7. Las normas $\|\cdot\|_1$ y $\|\cdot\|_2$ no son intercambiables en la práctica: la norma 1 suma magnitudes absolutas (es la que penaliza la regularización Lasso), mientras que la norma 2 suma cuadrados (su cuadrado es la penalización de la regularización Ridge y la que aparece en el error cuadrático medio que minimiza el descenso de gradiente) [5]. Confundir ambas normas, por ejemplo aplicar la fórmula de $\|\cdot\|_2$ pero sumar valores absolutos en vez de cuadrados, es un error frecuente que produce una cantidad que no es ninguna norma bien definida.

Ejemplo 5.8. Para $\vec{x} = (3,-4)$:

$$\begin{aligned}\|\vec{x}\|_1 &= |3|+|-4| = 7,\\ \|\vec{x}\|_2 &= \sqrt{3^2+(-4)^2} = \sqrt{25} = 5,\\ \|\vec{x}\|_\infty &= \max(|3|,|-4|) = 4.\end{aligned}$$

Ejemplo 5.9 (El error cuadrático medio como norma)**.** Con las predicciones del Ejemplo 3.6, $\hat{\vec{y}} = (5, 6, 10)^T$, y las etiquetas $\vec{y} = (6, 5, 12)^T$, el vector de residuos es $\vec{r} = \hat{\vec{y}} - \vec{y} = (-1, 1, -2)^T$. Por la Proposición 5.6, $\|\vec{r}\|_2^2 = \vec{r} \cdot \vec{r} = 1 + 1 + 4 = 6$, de modo que

$$\text{MSE}(2, 1, 1) = \frac{1}{2m} \sum_{i=1}^{m} \big(\hat{y}^{(i)} - y^{(i)}\big)^2 = \frac{1}{2m} \|\hat{\vec{y}} - \vec{y}\|_2^2 = \frac{6}{6} = 1.$$

El error cuadrático medio es, salvo la constante $\frac{1}{2m}$, el cuadrado de la norma euclidiana del vector de residuos; es el mismo valor $\text{MSE}(2, 1, 1) = 1$ que se calcula suma a suma en las notas de cálculo multivariable. Además, la predicción de cada neurona $\hat{y}^{(i)} = \vec{w} \cdot \vec{x}^{(i)} + b$ es un producto interno (Definición 5.1) más un sesgo.

Ejercicio 5.10. Determine si $\vec{u} = (1, 0, -1)$ y $\vec{v} = (1, 1, 1)$ son ortogonales, y calcule $\|\vec{u}\|_2$ y $\|\vec{v}\|_2$.

Solución.

$$\vec{u} \cdot \vec{v} = 1(1) + 0(1) + (-1)(1) = 1 + 0 - 1 = 0.$$

Por el Teorema 5.3, un producto interno nulo entre vectores no nulos implica $\cos\alpha = 0$, es decir, $\alpha = 90°$: $\vec{u}$ y $\vec{v}$ son ortogonales. Las normas son

$$\|\vec{u}\|_2 = \sqrt{1^2 + 0^2 + (-1)^2} = \sqrt{2}, \qquad \|\vec{v}\|_2 = \sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}.$$

△

Ejercicio 5.11. Calcule $\|\vec{x}\|_1$, $\|\vec{x}\|_2$ y $\|\vec{x}\|_\infty$ para $\vec{x} = (-2, 3, -6)$.

Síntesis de la sección

El producto interno mide, algebraica y geométricamente, cuánto apunta un vector en la dirección de otro, y se anula exactamente cuando los vectores son ortogonales; la norma generaliza la noción de magnitud de un vector, con la norma euclidiana como el caso inducido por el producto interno. Ambas construcciones reaparecerán, sin cambios, como el cómputo de una neurona dentro de una capa de una red neuronal profunda (Sección 7), como el error cuadrático medio (Ejemplo 5.9), y las normas 1 y 2 reaparecerán de nuevo al regularizar los pesos de esa red durante el entrenamiento. Con esta base, el lector debe poder calcular productos internos, ángulos y normas 1, 2 e ∞ de vectores concretos.

Soluciones de los ejercicios

Ejercicio 5.11.

$$\begin{aligned} \|\vec{x}\|_1 &= |-2| + |3| + |-6| = 2 + 3 + 6 = 11, \\ \|\vec{x}\|_2 &= \sqrt{(-2)^2 + 3^2 + (-6)^2} = \sqrt{4 + 9 + 36} = \sqrt{49} = 7, \\ \|\vec{x}\|_\infty &= \max(|-2|, |3|, |-6|) = 6. \end{aligned}$$

6 Normas matriciales

Así como la norma vectorial mide el tamaño de un vector, la norma matricial mide el tamaño de una matriz completa: por ejemplo, la magnitud total de una matriz de pesos W, o la sensibilidad de una transformación lineal ante perturbaciones de su entrada. Esta segunda lectura será relevante más adelante, al analizar cómo se propaga el error a través de las capas de una red durante el entrenamiento.

Definición 6.1 (Norma matricial)**.** Una *norma matricial* sobre $\mathbb{R}^{p\times q}$ es una función $\|\cdot\|\colon \mathbb{R}^{p\times q}\to\mathbb{R}$ que satisface los axiomas de norma vectorial (no negatividad, homogeneidad, desigualdad triangular) sobre el espacio vectorial de las matrices $p\times q$ [3].

Definición 6.2 (Norma de Frobenius)**.** Para $A\in\mathbb{R}^{p\times q}$,

$$\|A\|_F=\Big(\sum_{i=1}^{p}\sum_{j=1}^{q}A_{ij}^2\Big)^{1/2}.$$

Equivalentemente, $\|A\|_F=\sqrt{\operatorname{tr}(A^TA)}$, la raíz cuadrada de la traza de A^TA [4].

Definición 6.3 (Norma matricial inducida)**.** Dada una norma vectorial $\|\cdot\|_p$ en $\mathbb{R}^q$ y en $\mathbb{R}^p$, la *norma inducida* (u operador) de $A\in\mathbb{R}^{p\times q}$ es

$$\|A\|_p=\sup_{\vec{x}\neq\vec{0}}\frac{\|A\vec{x}\|_p}{\|\vec{x}\|_p},$$

es decir, el mayor factor de amplificación que A puede aplicar a un vector, medido en la norma p [3].

Teorema 6.4 (Norma espectral)**.** *La norma inducida-2 de $A\in\mathbb{R}^{p\times q}$ es igual a su mayor valor singular: $\|A\|_2=\sigma_{\max}(A)$, donde $\sigma_{\max}(A)$ es la raíz cuadrada del mayor valor propio de A^TA [4, cap. 2].*

Demostración. Véase [4, cap. 2] para la demostración completa, basada en la descomposición en valores singulares de A. □

Observación 6.5. La norma de Frobenius trata a A como un vector plano de pq entradas y no distingue direcciones; la norma espectral $\|A\|_2$, en cambio, mide la amplificación en la *peor* dirección posible. Ambas normas están relacionadas por $\|A\|_2\le\|A\|_F$, pero no son iguales en general: confundirlas lleva a subestimar cuánto puede amplificar A a un vector en la dirección más desfavorable.

Ejemplo 6.6. Para $A=\begin{pmatrix}1&2\\3&4\end{pmatrix}$,

$$\|A\|_F=\sqrt{1^2+2^2+3^2+4^2}=\sqrt{1+4+9+16}=\sqrt{30}\approx 5.477.$$

Ejemplo 6.7. Para la matriz diagonal $D=\begin{pmatrix}3&0\\0&4\end{pmatrix}$, sus valores singulares son 3 y 4 (los valores absolutos de sus entradas diagonales, al ser D diagonal), luego $\|D\|_2=\max(3,4)=4$.

Ejercicio 6.8. Calcule $\|A\|_F$ para $A=\begin{pmatrix}2&0&1\\1&2&2\end{pmatrix}$.

Solución.

$$\|A\|_F = \sqrt{2^2 + 0^2 + 1^2 + 1^2 + 2^2 + 2^2} = \sqrt{4 + 0 + 1 + 1 + 4 + 4} = \sqrt{14} \approx 3.742.$$

△

Ejercicio 6.9. Para la matriz diagonal $D = \begin{pmatrix} 5 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix}$, calcule $\|D\|_F$ y $\|D\|_2$, y verifique que $\|D\|_2 \leq \|D\|_F$.

Síntesis de la sección

La norma de Frobenius mide el tamaño total de una matriz sumando el cuadrado de todas sus entradas (útil para cuantificar la magnitud global de la matriz de pesos de una capa); la norma inducida mide, en cambio, la mayor amplificación que la matriz puede producir sobre un vector, y en el caso de la norma 2 esa amplificación máxima es el mayor valor singular de la matriz, la cantidad que determina si una capa amplifica o atenúa la señal que la atraviesa, relevante para entender por qué el gradiente puede explotar o desvanecerse al propagarse por varias capas de una red profunda. Con esta base, el lector debe poder calcular la norma de Frobenius de una matriz concreta y reconocer, para matrices diagonales, su norma espectral por inspección directa.

Soluciones de los ejercicios

Ejercicio 6.9.

$$\|D\|_F = \sqrt{5^2 + 1^2 + 2^2} = \sqrt{25 + 1 + 4} = \sqrt{30} \approx 5.477.$$

Al ser D diagonal, sus valores singulares son 5, 1 y 2, luego $\|D\|_2 = \max(5, 1, 2) = 5$. En efecto,

$$\|D\|_2 = 5 \leq \sqrt{30} \approx 5.477 = \|D\|_F.$$

7 Transformaciones lineales y la capa $W\vec{x} + \vec{b}$

Las secciones anteriores trataron a la matriz como un objeto que se multiplica por vectores; esta sección la trata como lo que realmente representa en un modelo: una función entre espacios vectoriales. Esa función es, precisamente, lo que una capa de una red neuronal aplica a su entrada. Formalizar esta idea con precisión, y distinguir con cuidado entre transformación *lineal* y transformación *afín*, es el objetivo de esta sección de cierre.

7.1 Transformaciones lineales

Definición 7.1 (Transformación lineal)**.** Sean V, W espacios vectoriales sobre $\mathbb{R}$. Una función $T\colon V \to W$ es una *transformación lineal* si para todo $\vec{u}, \vec{v} \in V$ y todo $\lambda \in \mathbb{R}$:

$$T(\vec{u} + \vec{v}) = T(\vec{u}) + T(\vec{v}) \qquad \text{y} \qquad T(\lambda\vec{u}) = \lambda\, T(\vec{u}).$$

Proposición 7.2. *Para toda $A \in \mathbb{R}^{p\times q}$, la función $T\colon \mathbb{R}^q \to \mathbb{R}^p$ dada por $T(\vec{x}) = A\vec{x}$ es una transformación lineal.*

Demostración. Por la Definición 3.3, la componente i de $A(\vec{u}+\vec{v})$ es $\sum_j A_{ij}(u_j+v_j) = \sum_j A_{ij}u_j + \sum_j A_{ij}v_j$, que es la componente i de $A\vec{u}+A\vec{v}$; por lo tanto $A(\vec{u}+\vec{v}) = A\vec{u}+A\vec{v}$. Análogamente, la componente i de $A(\lambda\vec{u})$ es $\sum_j A_{ij}(\lambda u_j) = \lambda\sum_j A_{ij}u_j$, la componente i de $\lambda(A\vec{u})$; por lo tanto $A(\lambda\vec{u}) = \lambda(A\vec{u})$. □

Teorema 7.3 (Representación matricial)**.** *Toda transformación lineal $T\colon \mathbb{R}^q \to \mathbb{R}^p$ puede representarse mediante una única matriz $A \in \mathbb{R}^{p\times q}$ tal que $T(\vec{x}) = A\vec{x}$ para todo $\vec{x} \in \mathbb{R}^q$; la columna j de A es $T(\vec{e}_j)$, la imagen del j-ésimo vector de la base canónica de $\mathbb{R}^q$ [2, cap. 8].*

Demostración. Véase [2, cap. 8] para la demostración completa, que escribe cualquier $\vec{x} \in \mathbb{R}^q$ como combinación lineal $\vec{x} = \sum_j x_j\vec{e}_j$ y aplica la linealidad de T para obtener $T(\vec{x}) = \sum_j x_j T(\vec{e}_j)$, que es exactamente $A\vec{x}$ por el Teorema 3.4. □

La Proposición 7.2 y el Teorema 7.3 son, juntos, la razón por la que "multiplicar por una matriz" y "aplicar una transformación lineal" son, en dimensión finita, la misma cosa vista desde dos ángulos: toda transformación lineal se representa como un producto matricial, y todo producto matricial define una transformación lineal.

7.2 La transformación afín $W\vec{x}+\vec{b}$

Observación 7.4 (Lineal no es lo mismo que afín). Sea $f(\vec{x}) = A\vec{x}+\vec{b}$ con $\vec{b} \neq \vec{0}$. Entonces f **no** es una transformación lineal: por la Definición 7.1, toda transformación lineal T satisface $T(\vec{0}) = T(0\cdot\vec{0}) = 0\cdot T(\vec{0}) = \vec{0}$, pero $f(\vec{0}) = A\vec{0}+\vec{b} = \vec{b} \neq \vec{0}$. Una función de esta forma se llama *transformación afín*: la composición de una transformación lineal ($\vec{x} \mapsto A\vec{x}$) con una traslación ($\vec{z} \mapsto \vec{z}+\vec{b}$). Referirse a $W\vec{x}+\vec{b}$ como "la parte lineal de la red" es, en sentido estricto, impreciso cuando $\vec{b} \neq \vec{0}$; lo correcto es llamarla la parte *afín* de la capa.

Definición 7.5 (Capa afín de una red neuronal)**.** Dada una entrada $\vec{x} \in \mathbb{R}^d$, una matriz de pesos $W \in \mathbb{R}^{p\times d}$ y un vector de sesgos $\vec{b} \in \mathbb{R}^p$, la *capa afín* asociada calcula la preactivación

$$\vec{z} = W\vec{x}+\vec{b} \in \mathbb{R}^p.$$

Cada fila i de W, denotada $\vec{w}_i \in \mathbb{R}^d$, es el vector de pesos de la neurona i-ésima de la capa, y b_i es su sesgo.

Teorema 7.6 (La neurona como producto interno)**.** *Para $\vec{z} = W\vec{x}+\vec{b}$ como en la Definición 7.5, cada componente se calcula como*

$$z_i = \vec{w}_i \cdot \vec{x} + b_i,$$

es decir, el producto interno (Definición 5.1) entre el vector de pesos de la neurona i y la entrada, más su sesgo.

Demostración. Por la Definición 3.3, $(W\vec{x})_i = \sum_j W_{ij}x_j$; como $\vec{w}_i = (W_{i1},\ldots,W_{id})$ es la fila i de W, esta suma es exactamente $\vec{w}_i\cdot\vec{x}$ por la Definición 5.1. Sumando b_i se obtiene $z_i = \vec{w}_i\cdot\vec{x}+b_i$. □

El Teorema 7.6 es el punto de llegada de este documento: la suma ponderada de entradas que calcula cada neurona artificial no es una operación nueva ni específica del aprendizaje automático; es, literalmente, el producto interno de la Sección 5, evaluado fila por fila de una matriz de pesos. Con $p = 1$ se recupera el modelo de entregas: $W = \vec{w}^T$, $\vec{b} = b$ y $\hat{y} = \vec{w}\cdot\vec{x}+b$.

Observación 7.7 (Un lote completo a la vez). Sea $X \in \mathbb{R}^{m\times d}$ la matriz de datos (Definición 3.1, con filas $\vec{x}^{(i)T}$). La preactivación del registro i es $\vec{z}^{(i)} = W\vec{x}^{(i)} + \vec{b}$, y su transpuesta es $\vec{z}^{(i)T} = \vec{x}^{(i)T}W^T + \vec{b}^T$. Apilando los m registros como filas,

$$Z = XW^T + \mathbf{1}\,\vec{b}^T \in \mathbb{R}^{m\times p}, \qquad \mathbf{1} = (1,\dots,1)^T \in \mathbb{R}^m,$$

de modo que una capa se evalúa sobre todo el conjunto de datos con un solo producto matricial. Con $p = 1$, $W = \vec{w}^T$ y $\vec{b} = b$, queda $\hat{\vec{y}} = X\vec{w} + b\,\mathbf{1}$, el cálculo del Ejemplo 3.6.

Proposición 7.8 (Composición de capas afines)**.** *Si $\vec{z}_1 = W_1\vec{x}+\vec{b}_1$ y $\vec{z}_2 = W_2\vec{z}_1+\vec{b}_2$ con $W_1 \in \mathbb{R}^{p\times d}$, $W_2 \in \mathbb{R}^{r\times p}$, entonces*

$$\vec{z}_2 = (W_2W_1)\vec{x} + (W_2\vec{b}_1 + \vec{b}_2) = W\vec{x} + \vec{b},$$

con $W \coloneqq W_2W_1 \in \mathbb{R}^{r\times d}$ y $\vec{b} \coloneqq W_2\vec{b}_1 + \vec{b}_2 \in \mathbb{R}^r$.

Demostración. Por la distributividad del producto matricial, $W_2(W_1\vec{x}+\vec{b}_1)+\vec{b}_2 = W_2W_1\vec{x}+W_2\vec{b}_1+\vec{b}_2$. □

La Proposición 7.8 dice que apilar dos capas afines produce de nuevo una capa afín, y el orden W_2W_1 es el que corresponde a aplicar primero W_1 (Proposición 3.8). Por eso, entre capa y capa, una red neuronal aplica a cada preactivación una función de activación no lineal: sin ella, toda la red equivaldría a una sola capa afín.

Ejemplo 7.9. Sea una capa con 3 entradas y 2 neuronas, con $W = \begin{pmatrix} 1 & -1 & 2 \\ 0 & 3 & 1 \end{pmatrix}$, $\vec{b} = (0.5, -1)^T$ y $\vec{x} = (2, 1, -1)^T$. Por la Definición 7.5,

$$W\vec{x} = \big(1(2) - 1(1) + 2(-1),\ 0(2) + 3(1) + 1(-1)\big)^T = (-1, 2)^T,$$

y

$$\vec{z} = W\vec{x} + \vec{b} = (-1 + 0.5,\ 2 - 1)^T = (-0.5,\ 1)^T.$$

Por el Teorema 7.6, la primera neurona calcula

$$\vec{w}_1 \cdot \vec{x} + b_1 = (1, -1, 2) \cdot (2, 1, -1) + 0.5 = (2 - 1 - 2) + 0.5 = -0.5,$$

que coincide.

Ejemplo 7.10 (Colapso de dos capas afines)**.** A la capa del Ejemplo 7.9 se le apila una segunda capa con una neurona, $W_2 = (1, 2)$ y $\vec{b}_2 = 3$. Por la Proposición 7.8,

$$W = W_2W_1 = \big(1 \cdot 1 + 2 \cdot 0,\ 1 \cdot (-1) + 2 \cdot 3,\ 1 \cdot 2 + 2 \cdot 1\big) = (1, 5, 4),$$

$$b = W_2\vec{b}_1 + b_2 = 1(0.5) + 2(-1) + 3 = 1.5.$$

Evaluando en $\vec{x} = (2, 1, -1)^T$: directamente, $W_2\vec{z}_1 + b_2 = 1(-0.5) + 2(1) + 3 = 4.5$; con la capa colapsada, $W\vec{x} + b = (2 + 5 - 4) + 1.5 = 4.5$. Ambos resultados coinciden.

Ejercicio 7.11. Para una capa con 2 entradas y 2 neuronas, con $W = \begin{pmatrix} 2 & -1 \\ 1 & 1 \end{pmatrix}$, $\vec{b} = (1, -2)^T$ y $\vec{x} = (3, -1)^T$, calcule $\vec{z} = W\vec{x} + \vec{b}$ e identifique el producto interno que calcula cada neurona.

Solución.

$$\begin{aligned} &\text{Neurona 1:} \quad \vec{w}_1 \cdot \vec{x} + b_1 = (2,-1)\cdot(3,-1) + 1 = (6+1)+1 = 8, \\ &\text{Neurona 2:} \quad \vec{w}_2 \cdot \vec{x} + b_2 = (1,1)\cdot(3,-1) + (-2) = (3-1)-2 = 0. \end{aligned}$$

Por lo tanto $\vec{z} = (8,0)^T$. △

Ejercicio 7.12. Explique, en una frase, por qué $f(\vec{x}) = W\vec{x} + \vec{b}$ con $\vec{b} \neq \vec{0}$ no satisface la Definición 7.1, usando específicamente la condición $T(\lambda\vec{u}) = \lambda T(\vec{u})$ con $\lambda = 2$.

Síntesis de la sección

Una transformación lineal preserva la suma y el escalado, y en dimensión finita toda transformación lineal es, sin excepción, un producto matricial (Teorema 7.3); la capa $W\vec{x}+\vec{b}$ de una red neuronal no es una transformación lineal cuando $\vec{b} \neq \vec{0}$, sino una transformación afín, y cada una de sus salidas es exactamente el producto interno entre una fila de W y la entrada, más un sesgo (Teorema 7.6). Encadenar varias de estas capas afines sin una función de activación no lineal colapsa en una sola (Proposición 7.8); por eso una red necesita esa función entre capa y capa. Con esta base, el lector debe poder calcular la salida de una capa afín a mano y explicar, con precisión y sin apelar a la intuición, por qué esa capa no es, en sentido estricto, una transformación lineal cuando incluye sesgo.

Soluciones de los ejercicios

Ejercicio 7.12. Con $\lambda = 2$:

$$f(2\vec{v}) = W(2\vec{v}) + \vec{b} = 2W\vec{v} + \vec{b}, \qquad \text{mientras que} \qquad 2f(\vec{v}) = 2(W\vec{v} + \vec{b}) = 2W\vec{v} + 2\vec{b}.$$

Como $\vec{b} \neq \vec{0}$, $\vec{b} \neq 2\vec{b}$, luego $f(2\vec{v}) \neq 2f(\vec{v})$: la condición de homogeneidad de la Definición 7.1 falla, por lo que f no es una transformación lineal (es afín, como señala la Observación 7.4).

8 Síntesis: del álgebra lineal al modelo

Las secciones anteriores no son temas independientes que resultan tener aplicaciones en aprendizaje profundo; son, en conjunto, la descripción algebraica completa de cómo se representan los datos y de cómo una capa de una red neuronal transforma esos datos en una predicción. La Tabla 2 resume la correspondencia entre cada construcción matemática desarrollada y el componente de la red que representa.

Tabla 2: Correspondencia entre las construcciones algebraicas de este documento y los componentes de un modelo lineal o de una capa de red neuronal.

Concepto matemático	Componente del modelo
Vector en $\mathbb{R}^d$ (Sección 2)	Un registro de datos, o el vector de pesos de una neurona
Matriz en $\mathbb{R}^{m\times d}$ (Sección 3)	Un dataset completo, o la matriz de pesos W de una capa
Producto matriz–vector, como combinación lineal de columnas (Secciones 3–4)	El cómputo simultáneo de todas las neuronas de una capa sobre una entrada; las predicciones $\hat{\vec{y}} = X\vec{w} + b\,\mathbf{1}$
Independencia lineal (Sección 4)	Ausencia de redundancia entre atributos de entrada; rango de una matriz de pesos
Producto interno (Sección 5)	La suma ponderada que calcula una neurona individual
Norma vectorial (Sección 5)	Magnitud de un vector de pesos o de error; el MSE como $\frac{1}{2m}\|\hat{\vec{y}} - \vec{y}\|_2^2$; base de la regularización L_1/L_2
Norma matricial (Sección 6)	Magnitud global de una matriz de pesos; sensibilidad de una capa ante perturbaciones de su entrada
Transformación afín $W\vec{x} + \vec{b}$ (Sección 7)	La operación elemental de una capa, previa a la aplicación de una función de activación no lineal
Composición W_2W_1 (Sección 7)	Dos capas afines sin activación equivalen a una sola

El resultado que articula toda la tabla es el Teorema 7.6: cada componente de $W\vec{x} + \vec{b}$ es un producto interno más un sesgo. Ese único hecho algebraico es, a la vez, la definición de una neurona artificial, la razón por la que una capa completa se calcula como un único producto matricial en lugar de neurona por neurona (Observación 7.7), y el punto de partida obligatorio para derivar, con las herramientas del cálculo multivariable [6], cómo se minimiza el MSE con el descenso por gradiente y cómo se propaga el error hacia atrás a través de las capas de la red durante el entrenamiento (*backpropagation*).

Referencias

[1] J. de J. Blanco Pérez, *Matemáticas para Ciencia de Datos*, cap. 2: "Vectores y Matrices", manuscrito en preparación, Universidad del Magdalena, 2026.

[2] G. Strang, *Introduction to Linear Algebra*, 5.ª ed., Wellesley-Cambridge Press, 2016.

[3] R. A. Horn y C. R. Johnson, *Matrix Analysis*, 2.ª ed., Cambridge University Press, 2013.

[4] G. H. Golub y C. F. Van Loan, *Matrix Computations*, 4.ª ed., Johns Hopkins University Press, 2013.

[5] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016, cap. 2: "Linear Algebra".

[6] J. Stewart, *Multivariable Calculus*, 8.ª ed., Cengage Learning, 2016.