Multivalue Calculus for Deep Learning

Notas de clase

Jairo de Jesús Blanco Pérez
Programa de Ingeniería de Sistemas, Universidad del Magdalena

Octubre de 2026

Resumen

Estas notas reúnen los conceptos de cálculo de varias variables que sostienen el entrenamiento de una red neuronal artificial. Se parte de las funciones escalares de varias variables, cuyo ejemplo central es la función de pérdida de un modelo; se definen la derivada parcial, el gradiente y la derivada direccional, y con esta última se demuestra que el gradiente apunta en la dirección de máximo crecimiento local. Sobre ese resultado se formula el descenso por gradiente, ilustrado en una variable, y se cierra con las funciones de activación clásicas (ReLU, sigmoide y tangente hiperbólica) y sus derivadas. Un mismo ejemplo, un modelo lineal que estima tiempos de entrega, acompaña las primeras secciones. Se asume familiaridad con vectores, producto punto, norma y producto de matrices.

Índice

1 Funciones de varias variables **1**

2 Derivada parcial **3**

3 Gradiente **4**

4 Derivada direccional **5**

5 Descenso por gradiente **6**

6 Funciones de activación y sus derivadas **8**
6.1 ReLU 8
6.2 Sigmoide 9
6.3 Tangente hiperbólica 9

1 Funciones de varias variables

En esta sección se define la función escalar de varias variables, se muestra que las funciones de pérdida de los modelos de aprendizaje son funciones de este tipo y se calcula, en un ejemplo concreto, el error cuadrático medio de un modelo lineal en un punto de su espacio de parámetros.

Definición 1.1 (Función escalar de varias variables)**.** Sea $D \subseteq \mathbb{R}^n$, $D \neq \varnothing$. Una *función escalar de n variables* es una aplicación

$$f\colon D \to \mathbb{R}, \qquad \vec{x} = (x_1, x_2, \ldots, x_n) \longmapsto f(\vec{x}) = f(x_1, x_2, \ldots, x_n),$$

que asigna a cada punto del dominio un número real.

Observación 1.2. A diferencia de la función escalar, una *función vectorial* $F\colon D \to \mathbb{R}^m$ con $m \geq 2$ asigna a cada punto del dominio un vector.

En el aprendizaje automático, la mayoría de las funciones de aprendizaje (de pérdida) de los modelos son funciones escalares de varias variables. Una función de pérdida es una aplicación $L\colon \mathbb{R}^n \to \mathbb{R}$, donde n es el número total de parámetros entrenables del modelo (pesos y sesgos), y $L(\vec{\theta})$ es un único número que representa qué tan mal predice el modelo con esos n parámetros. Para un modelo con vector de pesos $\vec{w}$ y sesgo b, evaluado sobre m registros con etiquetas $y^{(i)}$ y predicciones $\hat{y}^{(i)}$, un ejemplo es

$$L(\vec{\theta}) = L(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^{m} \big(\hat{y}^{(i)} - y^{(i)}\big)^2,$$

conocida como *error cuadrático medio*.

Ejemplo 1.3 (Tiempo de entrega)**.** Un ingeniero de datos ajusta un modelo lineal simple $\hat{y}^{(i)} = \vec{w} \cdot \vec{x}^{(i)} + b$ para una empresa de domicilios que quiere estimar el tiempo de entrega de un pedido antes de asignarlo a un repartidor. Para cada registro, el conjunto de datos guarda dos atributos: la distancia al destino en kilómetros (x_1) y el número de paradas previas que hace el repartidor (x_2). Se tienen $m = 3$ registros (Tabla 1).

Tabla 1: Registros del conjunto de datos de entregas.

Entrega i	$x_1^{(i)}$ (km)	$x_2^{(i)}$ (paradas previas)	$y^{(i)}$ (min reales)
1	1	2	6
2	2	1	5
3	3	3	12

El modelo es $\hat{y} = \vec{w} \cdot \vec{x} + b$, con $\vec{w} = (w_1, w_2)^T$ y $\vec{x}^{(i)} = \big(x_1^{(i)}, x_2^{(i)}\big)^T$, de modo que el vector de parámetros entrenables es $\vec{\theta} = (w_1, w_2, b)^T \in \mathbb{R}^3$. El error cuadrático medio se define como

$$\begin{aligned} \mathrm{MSE}\colon \mathbb{R}^3 \to \mathbb{R}, \qquad \mathrm{MSE}(\vec{\theta}) = \mathrm{MSE}(w_1, w_2, b) &= \frac{1}{2m} \sum_{i=1}^{m} \big(\hat{y}^{(i)} - y^{(i)}\big)^2 \\ &= \frac{1}{2m} \sum_{i=1}^{m} \big(\vec{w} \cdot \vec{x}^{(i)} + b - y^{(i)}\big)^2. \end{aligned}$$

Se pide calcular $\mathrm{MSE}(\vec{\theta})$ en $\vec{\theta} = (2, 1, 1)^T$, punto elegido aleatoriamente.

Solución. Con $m = 3$, $\vec{w} = (2, 1)^T$ y $b = 1$:

$$\begin{aligned} \mathrm{MSE}(2, 1, 1) &= \frac{1}{2(3)} \sum_{i=1}^{3} \left(\begin{pmatrix} 2 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} x_1^{(i)} \\ x_2^{(i)} \end{pmatrix} + 1 - y^{(i)} \right)^2 \\ &= \frac{1}{6} \sum_{i=1}^{3} \big(2x_1^{(i)} + x_2^{(i)} + 1 - y^{(i)}\big)^2. \end{aligned}$$

Sustituyendo los tres registros de la Tabla 1:

$$\begin{aligned}\mathrm{MSE}(2,1,1) &= \frac{1}{6}\Big[\big(2(1)+2+1-6\big)^2+\big(2(2)+1+1-5\big)^2+\big(2(3)+3+1-12\big)^2\Big]\\ &= \frac{1}{6}\Big[(5-6)^2+(6-5)^2+(10-12)^2\Big]\\ &= \frac{1}{6}(1+1+4)\\ &= 1.\end{aligned}$$

Por tanto, $\mathrm{MSE}(2,1,1) = 1$ min^2. △

Observación 1.4. La expresión general de la pérdida usa el factor $\frac{1}{m}$ y el Ejemplo 1.3 usa $\frac{1}{2m}$. Ambas difieren en una constante positiva, de modo que alcanzan su mínimo en los mismos parámetros. En lo que sigue se usa la versión con $\frac{1}{2m}$.

En las secciones siguientes se estudia cómo obtener un $\vec{\theta}^*$ óptimo tal que $\mathrm{MSE}(\vec{\theta}^*)$ sea mínimo. Incluso en $\mathbb{R}^3$ no es práctico encontrarlo por prueba y error. Esto importa porque los parámetros de $\vec{\theta}^*$ son los que debe calcular el modelo para realizar las mejores predicciones.

2 Derivada parcial

Para decidir cómo modificar un parámetro del modelo, primero hay que medir cómo cambia la pérdida cuando solo ese parámetro varía. Esa medida es la derivada parcial, que se define a continuación y se calcula sobre el ejemplo de la sección anterior.

Definición 2.1 (Derivada parcial)**.** Sea $f\colon D \to \mathbb{R}$ con $D \subseteq \mathbb{R}^n$, sea $\vec{x}_0 \in D$ y sea $\hat{e}_j \in \mathbb{R}^n$ el j-ésimo vector canónico, con 1 en la componente j y 0 en las demás, de modo que $\|\hat{e}_j\|_2 = 1$. La *derivada parcial de f respecto de x_j en $\vec{x}_0$* es la tasa de cambio instantánea de f en $\vec{x}_0$ en la dirección del vector canónico que apunta al eje de x_j:

$$\frac{\partial f}{\partial x_j}(\vec{x}_0) \coloneqq \lim_{h\to 0}\frac{f(\vec{x}_0 + h\hat{e}_j) - f(\vec{x}_0)}{h}.$$

Otra interpretación de la derivada parcial es la de pendiente de una recta tangente. Si se fijan las $n-1$ variables de f distintas de x_j en las componentes de $\vec{x}_0$, se obtiene una curva; cada una de esas fijaciones $x_k = x_{0,k}$ corresponde a un plano, y la curva es el corte de la gráfica de f con ellos. La derivada parcial $\frac{\partial f}{\partial x_j}(\vec{x}_0)$ es la pendiente de la recta tangente a esa curva en $\vec{x}_0$.

Notación.

$$\frac{\partial f}{\partial x_j} = f_{x_j} = D_j f.$$

En el contexto del aprendizaje automático, las derivadas parciales son la base del proceso de entrenamiento de los modelos, ya que mediante la optimización se busca el $\vec{\theta}^*$ que minimiza el MSE. Este proceso calcula los n parámetros con las derivadas parciales, agrupándolas en el gradiente, objeto que se formaliza en la Sección 3.

Ejemplo 2.2. Se continúa con el Ejemplo 1.3: el modelo lineal $\hat{y} = \vec{w}\cdot\vec{x} + b$, con $\vec{w} = (w_1, w_2)^T$ y tres registros etiquetados,

$$\vec{x}^{(1)} = (1,2)^T,\ y^{(1)} = 6; \qquad \vec{x}^{(2)} = (2,1)^T,\ y^{(2)} = 5; \qquad \vec{x}^{(3)} = (3,3)^T,\ y^{(3)} = 12,$$

en el punto $\vec{\theta} = (w_1, w_2, b)^T = (2, 1, 1)^T$, donde $\mathrm{MSE}(\vec{\theta}) = 1$. Se calcula $\frac{\partial \mathrm{MSE}}{\partial w_1}(2, 1, 1)$ para observar la tasa de cambio de la pérdida cuando w_1 aumenta, lo que ayuda a decidir si disminuir o aumentar el peso w_1. Este análisis sirve realmente cuando se hace con todas las variables a la vez para buscar candidatos a $\vec{\theta}^*$, proceso que se formaliza más adelante.

Solución. Escribiendo el producto punto por componentes,

$$\mathrm{MSE}(w_1, w_2, b) = \frac{1}{2m} \sum_{i=1}^{m} \big(w_1 x_1^{(i)} + w_2 x_2^{(i)} + b - y^{(i)}\big)^2,$$

y derivando respecto de w_1:

$$\begin{aligned} \frac{\partial \mathrm{MSE}}{\partial w_1}(w_1, w_2, b) &= \frac{1}{m} \sum_{i=1}^{m} \big(\hat{y}^{(i)} - y^{(i)}\big) x_1^{(i)} \\ &= \frac{1}{m} \Big[\big(\hat{y}^{(1)} - y^{(1)}\big) x_1^{(1)} + \big(\hat{y}^{(2)} - y^{(2)}\big) x_1^{(2)} + \big(\hat{y}^{(3)} - y^{(3)}\big) x_1^{(3)} \Big]. \end{aligned}$$

Con $m = 3$, los residuos obtenidos en el Ejemplo 1.3 y las distancias de la Tabla 1,

$$\hat{y}^{(1)} - y^{(1)} = -1, \quad \hat{y}^{(2)} - y^{(2)} = 1, \quad \hat{y}^{(3)} - y^{(3)} = -2; \qquad x_1^{(1)} = 1, \quad x_1^{(2)} = 2, \quad x_1^{(3)} = 3,$$

se obtiene

$$\begin{aligned} \frac{\partial \mathrm{MSE}}{\partial w_1}(2, 1, 1) &= \frac{1}{3} \big[(-1)(1) + (1)(2) + (-2)(3)\big] \\ &= -\frac{5}{3} \approx -1.667. \end{aligned}$$

Por tanto, $\frac{\partial \mathrm{MSE}}{\partial w_1}(2, 1, 1) < 0$. △

Como la tasa de cambio es negativa, en ese instante, con w_2 y b fijos, la función está decreciendo: si se aumenta w_1 manteniendo los mismos valores de w_2 y b, la pérdida disminuye localmente. A continuación se formaliza el gradiente, la herramienta que permite hacer este análisis en todas las direcciones.

3 Gradiente

El Ejemplo 2.2 midió el efecto de un solo parámetro. Para mover todos los parámetros a la vez se necesita reunir las n derivadas parciales en un único objeto.

Definición 3.1 (Gradiente)**.** Sea $f\colon D \to \mathbb{R}$ con $D \subseteq \mathbb{R}^n$ y $\vec{x}_0 \in D$, tal que existen las n derivadas parciales de primer orden de f en $\vec{x}_0$: $\frac{\partial f}{\partial x_1}(\vec{x}_0), \frac{\partial f}{\partial x_2}(\vec{x}_0), \ldots, \frac{\partial f}{\partial x_n}(\vec{x}_0)$. El *gradiente de f en $\vec{x}_0$* es el vector de $\mathbb{R}^n$ que tiene como componentes las n derivadas parciales:

$$\nabla f(\vec{x}_0) \coloneqq \left(\frac{\partial f}{\partial x_1}(\vec{x}_0), \frac{\partial f}{\partial x_2}(\vec{x}_0), \ldots, \frac{\partial f}{\partial x_n}(\vec{x}_0) \right)^T \in \mathbb{R}^n.$$

El vector gradiente $\nabla f(\vec{x}_0)$ apunta en la dirección de máximo crecimiento local de f en $\vec{x}_0$, y su opuesto, $-\nabla f(\vec{x}_0)$, apunta en la dirección de máximo decrecimiento local de f en $\vec{x}_0$. En el aprendizaje automático esta es la base de los métodos de optimización basados en gradiente, que tienen un costo por iteración mucho menor que el de los métodos de segundo orden, como el de Newton [2, §8.6.1].

Esta afirmación se demuestra en la Sección 4 (Teorema 4.3); para ello se define un último concepto que se necesita antes de pasar a la parte algorítmica de las redes neuronales artificiales.

4 Derivada direccional

La derivada parcial mide la tasa de cambio solo a lo largo de los ejes. Para comparar todas las direcciones posibles, y así justificar el papel del gradiente, se generaliza a una dirección unitaria arbitraria.

Definición 4.1 (Derivada direccional)**.** Sea $f\colon D \to \mathbb{R}$ con $D \subseteq \mathbb{R}^n$, sea $\vec{x}_0 \in D$ y sea $\hat{u} \in \mathbb{R}^n$ un vector unitario ($\|\hat{u}\|_2 = 1$). La *derivada direccional de f en $\vec{x}_0$ en la dirección de $\hat{u}$* es

$$D_{\hat{u}} f(\vec{x}_0) \coloneqq \lim_{h \to 0} \frac{f(\vec{x}_0 + h\hat{u}) - f(\vec{x}_0)}{h}.$$

Proposición 4.2. *Si f es diferenciable en $\vec{x}_0$, entonces*

$$D_{\hat{u}} f(\vec{x}_0) = \left\langle \nabla f(\vec{x}_0), \hat{u} \right\rangle.$$

Demostración. Véase [1, §14.6]. □

Esta es una generalización del concepto de derivada parcial: ya no se analiza la tasa de cambio solo en la dirección del eje de una variable, sino en cualquier dirección. En particular, tomando $\hat{u} = \hat{e}_j$, con $\|\hat{e}_j\|_2 = 1$,

$$\frac{\partial f}{\partial x_j}(\vec{x}_0) = D_{\hat{e}_j} f(\vec{x}_0) = \left\langle \nabla f(\vec{x}_0), \hat{e}_j \right\rangle.$$

Con la Proposición 4.2 se demuestra la afirmación de la Sección 3.

Teorema 4.3 (Dirección de máximo crecimiento)**.** *Sea f diferenciable en $\vec{x}_0$ con $\nabla f(\vec{x}_0) \neq \vec{0}$. Entre todos los vectores unitarios $\hat{u}$, la derivada direccional $D_{\hat{u}} f(\vec{x}_0)$ alcanza su valor máximo, $\|\nabla f(\vec{x}_0)\|$, en la dirección*

$$\widehat{\nabla} f(\vec{x}_0) \coloneqq \frac{\nabla f(\vec{x}_0)}{\|\nabla f(\vec{x}_0)\|},$$

y su valor mínimo, $-\|\nabla f(\vec{x}_0)\|$, en la dirección $-\widehat{\nabla} f(\vec{x}_0)$.

Demostración. Por la Proposición 4.2, $D_{\hat{u}} f(\vec{x}_0) = \langle \nabla f(\vec{x}_0), \hat{u} \rangle$. Geométricamente, el producto punto de dos vectores $\vec{a}, \vec{c}$ cumple $\langle \vec{a}, \vec{c} \rangle = \|\vec{a}\| \, \|\vec{c}\| \cos\alpha$, donde α es el ángulo entre ellos. Tomando como α el ángulo entre $\nabla f(\vec{x}_0)$ y $\hat{u}$, y usando $\|\hat{u}\| = 1$:

$$\begin{aligned} D_{\hat{u}} f(\vec{x}_0) &= \|\nabla f(\vec{x}_0)\| \, \|\hat{u}\| \cos\alpha \\ &= \|\nabla f(\vec{x}_0)\| \cos\alpha. \end{aligned}$$

Como $\cos\alpha \in [-1, 1]$ para todo $\alpha \in \mathbb{R}$, el valor es máximo cuando $\cos\alpha = 1$ y mínimo cuando $\cos\alpha = -1$, porque

$$-\|\nabla f(\vec{x}_0)\| \leq \|\nabla f(\vec{x}_0)\| \cos\alpha \leq \|\nabla f(\vec{x}_0)\|.$$

Máximo. Si $\cos\alpha = 1$, entonces

$$\max_{\|\hat{u}\|=1} \{D_{\hat{u}} f(\vec{x}_0)\} = \|\nabla f(\vec{x}_0)\|,$$

es decir, la máxima tasa de cambio local coincide con la magnitud del gradiente. El caso $\cos\alpha = 1$ corresponde a $\hat{u}$ con la misma dirección y sentido que $\nabla f(\vec{x}_0)$, de modo que la dirección de máximo crecimiento local en $\vec{x}_0$ es $\widehat{\nabla} f(\vec{x}_0)$.

Mínimo. Si $\cos\alpha = -1$, entonces

$$\min_{\|\hat{u}\|=1} \{D_{\hat{u}} f(\vec{x}_0)\} = -\|\nabla f(\vec{x}_0)\|,$$

es decir, la mínima tasa de cambio local coincide con menos la magnitud del gradiente. El caso $\cos\alpha = -1$ corresponde a $\hat{u}$ de sentido opuesto a $\nabla f(\vec{x}_0)$, de modo que la dirección de mayor decrecimiento local en $\vec{x}_0$ es

$$-\widehat{\nabla} f(\vec{x}_0) = -\frac{\nabla f(\vec{x}_0)}{\|\nabla f(\vec{x}_0)\|}. \qquad \square$$

5 Descenso por gradiente

El Teorema 4.3 dice hacia dónde decrece más rápido la pérdida en el punto actual. El descenso por gradiente convierte esa información local en un procedimiento iterativo para aproximar $\vec{\theta}^*$.

Definición 5.1 (Descenso por gradiente)**.** Sea $L\colon \mathbb{R}^n \to \mathbb{R}$ la función de pérdida. El *descenso por gradiente* con tasa de aprendizaje $\eta > 0$ y punto inicial $\vec{\theta}_0$ es la recurrencia

$$\vec{\theta}_{k+1} = \vec{\theta}_k - \eta\, \nabla L(\vec{\theta}_k), \qquad k = 0, 1, 2, \ldots$$

El algoritmo se detiene cuando $\|\nabla L(\vec{\theta}_k)\| < \varepsilon$ o al alcanzar un número máximo de iteraciones.

En la recurrencia:

- $\nabla L(\vec{\theta}_k)$ es el gradiente de la pérdida en el punto actual.
- $\eta > 0$ es la tasa de aprendizaje, que controla qué tan grande es cada paso. Si $\eta \gg \eta^*$, con η^* una tasa óptima, el algoritmo diverge; si $\eta \ll \eta^*$, avanza demasiado lento.

Si $\nabla L(\vec{\theta}) \neq \vec{0}$, se puede escribir

$$\widehat{\nabla} L(\vec{\theta}) = \frac{\nabla L(\vec{\theta})}{\|\nabla L(\vec{\theta})\|}.$$

El paso se justifica porque $-\nabla L(\vec{\theta})$ es la dirección local de máximo decrecimiento (Teorema 4.3). Reescribiendo la recurrencia,

$$\vec{\theta}_{k+1} = \vec{\theta}_k - \eta\, \|\nabla L(\vec{\theta}_k)\|\, \widehat{\nabla} L(\vec{\theta}_k),$$

donde $\eta\|\nabla L(\vec{\theta}_k)\|$ es el tamaño del paso y $-\widehat{\nabla} L(\vec{\theta}_k)$ es su dirección.

Observación 5.2. Que L se minimice correctamente depende de que η sea lo suficientemente pequeña, ya que el carácter de $-\nabla L(\vec{\theta})$ como dirección de mayor decrecimiento solo es verdadero localmente.

Ejemplo 5.3. Se considera una pérdida de una variable, $L(w) = (w-2)^2$, con $\eta = 0.25$. En este caso la recurrencia es

$$w_{k+1} = w_k - \eta\, \frac{dL}{dw}(w_k).$$

La Figura 1 muestra cómo el gradiente (que en el caso unidimensional es la derivada), ponderado por la tasa de aprendizaje, conduce hacia el mínimo local en las tres primeras iteraciones desde $w_0 = 1$.

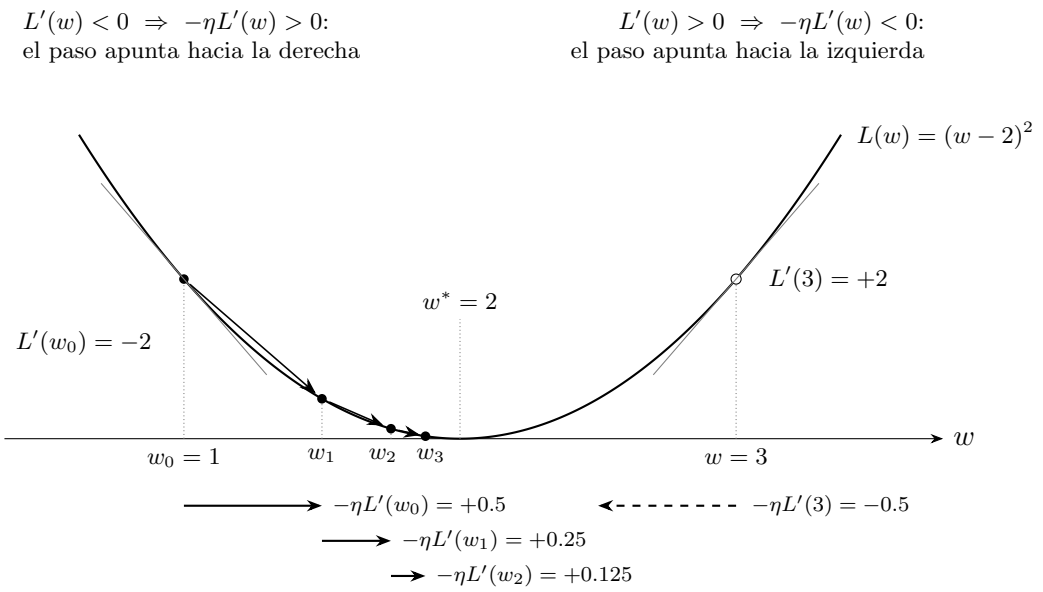


Figura 1: Las tres primeras iteraciones del Ejemplo 5.3 ($L(w) = (w-2)^2$, $\eta = 0.25$, $w_0 = 1$). Debajo del eje se dibuja cada paso $-\eta L'(w_k)$: como $L'(w_k) < 0$, el paso es positivo y apunta hacia la derecha, y su longitud se reduce a la mitad en cada iteración. El punto blanco $w = 3$ es ilustrativo: allí $L'(3) > 0$, de modo que el paso cambia de sentido y apunta hacia la izquierda.

Solución. La derivada es $L'(w) = 2(w-2)$, de modo que la recurrencia queda

$$\begin{aligned} w_{k+1} &= w_k - 2\eta\,(w_k - 2) \\ &= w_k - \tfrac{1}{2}(w_k - 2), \qquad \text{con } \eta = \tfrac{1}{4}. \end{aligned}$$

Partiendo de $w_0 = 1$:

Iteración 1.

$$w_1 = 1 - \tfrac{1}{2}(1-2) = 1 + \tfrac{1}{2} = \tfrac{3}{2} = 1.5.$$

Iteración 2.

$$w_2 = \tfrac{3}{2} - \tfrac{1}{2}\left(\tfrac{3}{2} - 2\right) = \tfrac{3}{2} + \tfrac{1}{4} = \tfrac{7}{4} = 1.75.$$

Iteración 3.

$$w_3 = \tfrac{7}{4} - \tfrac{1}{2}\left(\tfrac{7}{4} - 2\right) = \tfrac{7}{4} + \tfrac{1}{2}\left(\tfrac{1}{4}\right) = \tfrac{15}{8} = 1.875.$$

$$\vdots$$

Iteración 8.

$$w_8 = \tfrac{255}{128} - \tfrac{1}{2}\left(\tfrac{255}{128} - 2\right) = \tfrac{255}{128} + \tfrac{1}{256} = \tfrac{511}{256} \approx 1.99609.$$

Cuando $k \to \infty$, $w_k \to w^* = 2$. Con el criterio de parada $|L'(w_k)| < \varepsilon = 1 \cdot 10^{-8}$, la condición se cumple por primera vez en $k = 28$, donde $|L'(w_{28})| \approx 7.45 \cdot 10^{-9}$. △

En el contexto del aprendizaje profundo, el descenso por gradiente y sus variantes, en particular el estocástico [2, §8.3.1], son los métodos habituales del proceso de aprendizaje para minimizar la función de pérdida $L(\vec{\theta})$ y encontrar el vector óptimo $\vec{\theta}^*$, cuyas componentes son los pesos y sesgos $(w_1^*, w_2^*, \ldots, b^*)^T$ del modelo.

6 Funciones de activación y sus derivadas

Una neurona artificial calcula primero su *preactivación*

$$z = \vec{w} \cdot \vec{x} + b.$$

Si la salida fuera z tal cual, la neurona sería una función afín de $\vec{x}$ (una recta si la entrada es escalar, un plano si tiene dos componentes y, en general, un hiperplano). Una red multicapa compone varias capas densas, y con salidas afines la composición de dos capas da

$$W_2\big(W_1\vec{x} + \vec{b}_1\big) + \vec{b}_2 = \big(W_2W_1\big)\vec{x} + \big(W_2\vec{b}_1 + \vec{b}_2\big) = W\vec{x} + \vec{b},$$

con $W \coloneqq W_2W_1$ y $\vec{b} \coloneqq W_2\vec{b}_1 + \vec{b}_2$. El resultado de apilar dos capas es otra capa: no cambia la naturaleza de la transformación.

Definición 6.1 (Función de activación)**.** Una *función de activación* es una función no lineal $\varphi\colon \mathbb{R} \to \mathbb{R}$ que se aplica sobre z, con salida $a = \varphi(z)$; en la neurona de salida, $\hat{y} = a = \varphi(z)$.

La función de activación rompe la linealidad de z, de modo que la red pueda representar relaciones que una transformación afín no puede. Como la red se entrena con la técnica del gradiente, estas funciones tienen que ser derivables en casi todo su dominio. A continuación se presentan las funciones de activación clásicas.

6.1 ReLU

Definición 6.2 (ReLU)**.**

$$\mathrm{ReLU}(z) = \max\{0, z\}, \qquad \operatorname{dom}\mathrm{ReLU} = (-\infty, \infty), \qquad \operatorname{ran}\mathrm{ReLU} = [0, \infty).$$

Su derivada es

$$\mathrm{ReLU}'(z) = \begin{cases} 1, & z > 0, \\ 0, & z < 0, \end{cases} \qquad \mathrm{ReLU}'(0) \coloneqq 0.$$

Observación 6.3. ReLU no es diferenciable en $z = 0$; el valor $\mathrm{ReLU}'(0) = 0$ es una convención.

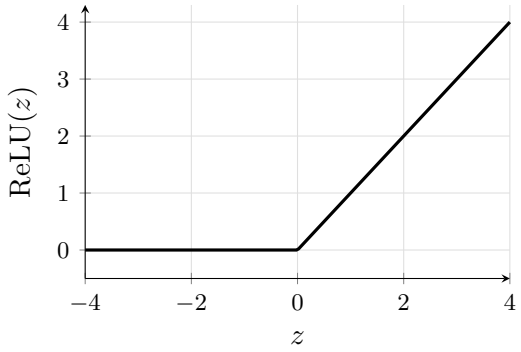


Figura 2: Función $\mathrm{ReLU}(z) = \max\{0, z\}$.

6.2 Sigmoide

Definición 6.4 (Sigmoide)**.**

$$\sigma(z) = \frac{1}{1+e^{-z}}, \qquad \operatorname{dom}\sigma = (-\infty, \infty), \qquad \operatorname{ran}\sigma = (0,1).$$

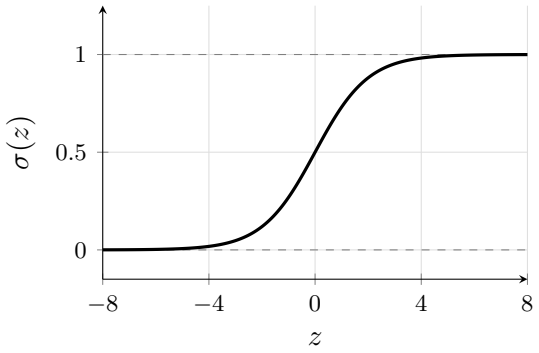


Figura 3: Función sigmoide $\sigma(z) = 1/(1+e^{-z})$, con asíntotas $y = 0$ y $y = 1$.

Derivando $\sigma(z) = (1+e^{-z})^{-1}$:

$$\begin{aligned}
\sigma'(z) &= -\frac{\left(-e^{-z}\right)}{\left(1+e^{-z}\right)^2} \\
&= \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}+1-1}{1+e^{-z}} \\
&= \underbrace{\frac{1}{1+e^{-z}}}_{\sigma(z)} \cdot \underbrace{\left(1 - \frac{1}{1+e^{-z}}\right)}_{1-\sigma(z)}.
\end{aligned}$$

Por tanto,

$$\sigma'(z) = \sigma(z)\big(1-\sigma(z)\big).$$

6.3 Tangente hiperbólica

Definición 6.5 (Tangente hiperbólica)**.**

$$\tanh(z) = \frac{1-e^{-2z}}{1+e^{-2z}}, \qquad \operatorname{dom}\tanh = (-\infty, \infty), \qquad \operatorname{ran}\tanh = (-1,1).$$

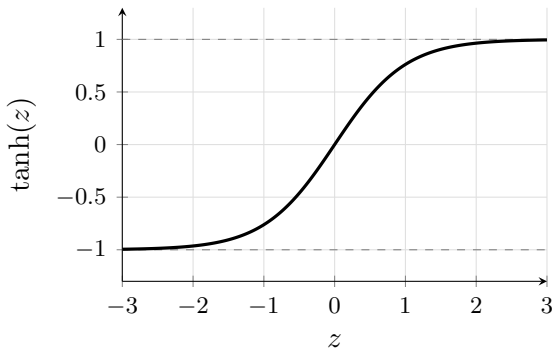


Figura 4: Función $\tanh(z) = (1 - e^{-2z})/(1 + e^{-2z})$, con asíntotas $y = \pm 1$.

Escribiendo $\tanh(z) = \dfrac{\sinh(z)}{\cosh(z)}$ y aplicando la regla del cociente:

$$\begin{aligned} \tanh'(z) &= \frac{\cosh^2(z) - \sinh^2(z)}{\cosh^2(z)} \\ &= 1 - \tanh^2(z). \end{aligned}$$

Referencias

[1] J. Stewart, *Multivariable Calculus*, 8.ª ed., Cengage Learning, 2016.

[2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*, MIT Press, 2016.